



UNIVERSIDADE FEDERAL DE SERGIPE

DEPARTAMENTO DE COMPUTAÇÃO

DISCIPLINA: PROCESSAMENTO DE IMAGENS

PreOCR: Detecção de Colunas, Linhas e Palavras em Imagens Binárias

Discentes (Grupo 13):

Evandro José dos Santos Neto

Gabriel Rodrigues dos Santos

Gustavo de Jesus Rodrigues

João Felipe Tunes Oliveira

Docente: Beatriz Trinchao Andrade de Carvalho

Julho de 2026

Sumário

1	INTRODUÇÃO	2
2	TÉCNICAS APLICADAS	2
2.1	Leitura e escrita do formato PBM	2
2.2	Remoção do ruído sal e pimenta	2
2.3	Segmentação de palavras, linhas e colunas	3
2.4	Parâmetros	3
3	PRINCIPAIS PROBLEMAS E SOLUÇÕES	4
4	RESULTADOS	4
5	OUTROS TIPOS DE FONTE	5
6	TRATAMENTO DE ERROS	6
7	COMPILAÇÃO E EXECUÇÃO	6
	REFERÊNCIAS	8

1 INTRODUÇÃO

Este trabalho apresenta o PreOCR, um programa que recebe pela linha de comando uma imagem binária no formato PBM ASCII (tipo P1) contendo um texto com uma ou mais colunas, e retorna no terminal a quantidade de colunas, linhas e palavras desse texto. O programa também gera duas imagens de saída: uma versão filtrada da entrada, sem o ruído sal e pimenta, e uma versão em que cada palavra aparece circunscrita por um retângulo. Um sistema desse tipo corresponde à etapa de segmentação que antecede o reconhecimento óptico de caracteres (OCR), na qual as regiões da imagem que contêm palavras são localizadas antes de qualquer tentativa de identificação das letras [1].

O programa foi escrito em Python, usando apenas a biblioteca padrão da linguagem. Todas as funções de processamento de imagens foram implementadas pelo grupo, sem o uso de bibliotecas prontas como OpenCV, NumPy ou Pillow. As técnicas aplicadas vêm das aulas de Morfologia Matemática da disciplina, que tratam a imagem binária como um conjunto de pontos em $\mathbb{Z}^2$ e a manipulam com operações entre esse conjunto e um elemento estruturante [1, 2]. Adotamos a convenção vista em aula, em que o valor 1 representa o pixel preto (texto) e o valor 0 representa o pixel branco (fundo).

Além do programa, foram criadas três imagens de teste de autoria do grupo, nomeadas no formato pedido na especificação, e o conjunto foi validado sobre as dez imagens da base de teste disponibilizada no SIGAA.

2 TÉCNICAS APLICADAS

2.1 Leitura e escrita do formato PBM

O PBM ASCII é um formato de imagem binária sem compressão, composto por um cabeçalho com o número mágico P1, a largura e a altura, seguido pelos valores 0 e 1 dos pixels [3]. O leitor implementado remove os comentários iniciados por #, aceita os bits escritos juntos ou separados por espaços e valida o arquivo por completo: formato, dimensões, quantidade de pixels e valores permitidos. Qualquer problema gera uma mensagem de erro clara para o usuário.

2.2 Remoção do ruído sal e pimenta

O enunciado garante que o ruído tem o tamanho de um pixel. Um pixel preto isolado é detectado pela transformada hit-or-miss [1], com o elemento estruturante composto pela origem (objeto) e pela vizinhança-8 (fundo). A remoção corresponde à operação de afinamento, $A \otimes B = A - (A \circledast B)$. O caso do pixel branco isolado dentro de uma letra é o dual, resolvido pelo espessamento, que preenche o buraco.

Nas imagens com ruído mais denso da base de teste, observamos que pixels de ruído vizinhos formam pares e trincas que a transformada de pixel isolado não alcança. Para removê-los, aplicamos uma erosão por um quadrado 2×2 , que gera um marcador: como os traços das letras têm espessura de pelo menos 2 pixels, o marcador sobrevive somente dentro do texto verdadeiro, e os aglomerados de ruído desaparecem. Em seguida, a extração de componentes conexos a partir das sementes do marcador, dada pela iteração $X_k = (X_{k-1} \oplus B) \cap A$ até a estabilização [1, 2], reconstrói apenas os componentes que contêm texto. Verificamos que nenhum componente legítimo da base de teste é perdido nesse processo. Consideramos usar uma abertura para essa etapa, mas ela danificaria os traços finos das letras, que têm espessura próxima do tamanho do elemento estruturante.

2.3 Segmentação de palavras, linhas e colunas

A ideia central da segmentação é que o espaço entre letras de uma mesma palavra é bem menor que o espaço entre palavras, que por sua vez é bem menor que o corredor entre colunas. Um fechamento $A \bullet B = (A \oplus B) \ominus B$ com elemento estruturante em reta horizontal, com raio proporcional ao tamanho da letra, funde as letras de cada palavra sem fundir palavras vizinhas. Essa estratégia de suavização por varredura é semelhante à usada em sistemas clássicos de análise de documentos [4]. Um segundo fechamento, com elemento em reta vertical de raio 2, une o pingo do i e do j ao corpo da palavra. Depois disso, cada palavra vira um único componente conexo, e a contagem é feita pela extração de componentes conexos vista em aula.

Para as colunas, um fechamento horizontal maior une as palavras de cada linha sem atravessar o corredor entre colunas, e uma dilatação vertical com elemento do tamanho da altura da imagem funde todas as linhas de uma mesma coluna em um único bloco. Como essa dilatação é puramente vertical, colunas distintas nunca se unem. As linhas são contadas dentro da faixa de cada coluna: uma dilatação horizontal seguida da interseção com a máscara da coluna transforma cada linha do texto em uma faixa conexa, e basta contar as faixas. Com isso, linhas de colunas diferentes contam separadamente, como pede a especificação.

Os retângulos da imagem de saída são as caixas delimitadoras dos pixels de texto de cada componente palavra, com uma margem de 2 pixels. Como o texto filtrado é subconjunto do seu fechamento, propriedade vista em aula [1], os rótulos dos componentes fundidos podem ser usados diretamente sobre os pixels originais.

2.4 Parâmetros

Todos os raios são calculados em relação à altura mediana h dos componentes conexos da imagem filtrada, estimada da própria imagem. Assim o programa funciona para qualquer corpo de fonte, sem valores fixos em pixels. Os parâmetros usados foram: raio do fechamento de palavras igual a $0,22 \cdot h$, raio do fechamento vertical do pingo igual a 2, raio do fechamento

de linhas igual a $1,0 \cdot h$ e margem dos retângulos igual a 2 pixels. Na base de teste, h ficou em torno de 18 pixels.

3 PRINCIPAIS PROBLEMAS E SOLUÇÕES

O primeiro problema encontrado foi o dos pingos de i e j e dos sinais de pontuação, que viravam palavras separadas (havia 368 componentes de altura 3 na base de teste). Medimos o vão vertical entre o pingo e o corpo da letra, que é de 3 pixels, e resolvemos com o fechamento vertical de raio 2, que une o pingo à palavra sem alcançar a linha vizinha.

O segundo problema foi o ruído denso, que forma pares e trincas de pixels. Após o hit-or-miss de pixel isolado ainda restavam 1.315 aglomerados na imagem `lorem_s12_c03_noise`. A solução do marcador por erosão 2×2 com reconstrução por componentes conexos, descrita na seção anterior, eliminou todos sem perder nenhuma letra.

O terceiro problema apareceu nas variantes justificadas e com espaços vazios da base. Os espaços esticados do texto justificado quebravam a contagem de linhas, e os espaços vazios dividiam uma coluna em vários blocos. A solução foi contar as colunas com uma dilatação puramente vertical, que é insensível a vãos verticais, e contar as linhas por faixas horizontais dentro da máscara de cada coluna, o que é insensível ao espaçamento horizontal.

Também tratamos com cuidado as bordas das operações morfológicas. Pela dualidade $(A \ominus B)^c = A^c \oplus \hat{B}$, o complemento de A em $\mathbb{Z}^2$ é infinito, então o que está fora da imagem conta como fundo na erosão. No fechamento, a dilatação intermediária é calculada com o domínio estendido, para não violar a propriedade $A \subseteq A \bullet B$.

Por fim, a eficiência. A dilatação e a erosão unidimensionais foram implementadas em tempo $O(N)$ por varredura dupla, medindo a distância de cada pixel ao objeto mais próximo, o que independe do raio do elemento estruturante. A extração de componentes conexos usa uma fila e visita cada pixel uma única vez, sendo a realização eficiente da definição iterativa da aula. Uma página A4 (1653 por 2338 pixels) é processada em cerca de 10 a 15 segundos em Python puro.

4 RESULTADOS

O gabarito de palavras foi extraído dos arquivos `.odt` que acompanham a base de teste. As contagens do programa foram exatas nas dez imagens, incluindo todas as versões com ruído, como mostra a Tabela 1.

O texto justificado tem exatamente as mesmas quebras de linha do texto não justificado (99 linhas nas duas versões de duas colunas e 150 nas de três colunas), o que confirma a contagem de linhas. As três imagens de autoria do grupo também retornam exatamente os valores presentes nos nomes dos arquivos: 1 coluna, 13 linhas e 108 palavras na primeira; 2 colunas,

Tabela 1: Resultados nas imagens da base de teste (com e sem ruído).

Imagem	Colunas	Linhas	Palavras
lorem_s12_c02	2	99	583
lorem_s12_c02_espacos	2	81	476
lorem_s12_c02_just	2	99	583
lorem_s12_c03	3	150	557
lorem_s12_c03_just	3	150	557

38 linhas e 170 palavras na segunda; 3 colunas, 61 linhas e 223 palavras na terceira.

As Figuras 1, 2 e 3 mostram um recorte de uma das imagens da base: a entrada com ruído, o resultado da filtragem e a saída final com as palavras circunscritas.




Figura 1: Recorte da imagem de entrada com ruído sal e pimenta.

5 OUTROS TIPOS DE FONTE

Verificamos o comportamento do programa com textos escritos em fontes diferentes da Arial. Geramos imagens de teste nas fontes Times New Roman (serifada) e Verdana (sem serifa) e o programa retornou as contagens exatas nas duas, sem a alteração de nenhum parâmetro. Isso acontece porque todos os raios são relativos à altura mediana da letra, estimada da própria imagem, e porque a proporção entre o espaço de letras e o espaço de palavras se mantém nas fontes proporcionais. As imagens desses testes estão na pasta extras do projeto.

Identificamos, porém, uma limitação com fontes monoespaçadas, como a Courier. Nelas, cada caractere ocupa uma célula de largura fixa, então o espaço entre letras se aproxima do espaço entre palavras e o fechamento com raio proporcional deixa de separar bem os dois casos.

Lorem ipsum dolor sit amet, consectetur adipiscing elit, sed do eiusmod tempor incididunt ut labore et dolore magna aliqua. Ut enim ad minim veniam, quis nostrud exercitation ullamco laboris nisi ut aliquip ex ea commodo consequat. Duis aute irure dolor in reprehenderit in voluptate velit esse cillum dolore eu fugiat nulla pariatur. Excepteur sint occaecat cupidatat non proident, sunt in culpa qui officia deserunt mollit anim id est laborum.	non recus tenetur a s reiciendis ' consequat asperiores Lorem ipsi adipiscing incididunt ' Ut enim ac exercitatio ea commo dolor in re cillum dolo
Sed ut perspiciatis unde omnis iste natus error sit voluptatem accusantium	

Figura 2: Mesmo recorte após a remoção do ruído.

Uma extensão natural do trabalho seria estimar o limiar de fusão pela análise do histograma dos vãos horizontais de cada linha, em vez de usar uma proporção fixa da altura da letra.

6 TRATAMENTO DE ERROS

O programa rejeita, com mensagem clara no terminal: arquivo inexistente ou ilegível, formato diferente de P1, cabeçalho incompleto, dimensões inválidas, arquivo truncado e valores de pixel diferentes de 0 e 1. Uma imagem válida sem nenhum texto retorna 0 colunas, 0 linhas e 0 palavras, e as imagens de saída são geradas normalmente.

7 COMPILAÇÃO E EXECUÇÃO

O programa não requer compilação nem instalação de dependências, apenas o interpretador Python 3 (versão 3.6 ou superior), presente por padrão nas principais distribuições Linux. Para executar:

```
python3 PreOCR.py lorem_s12_c02.pbm
```

A saída no terminal informa as contagens:

```
colunas: 2
linhas: 99
palavras: 583
```

Lorem ipsum dolor sit amet, consectetur adipiscing elit, sed do eiusmod tempor incididunt ut labore et dolore magna aliqua. Ut enim ad minim veniam, quis nostrud exercitation ullamco laboris nisi ut aliquip ex ea commodo consequat. Duis aute irure dolor in reprehenderit in voluptate velit esse cillum dolore eu fugiat nulla pariatur. Excepteur sint occaecat cupidatat non proident, sunt in culpa qui officia deserunt mollit anim id est laborum. Sed ut perspiciatis unde omnis iste natus error sit voluptatem accusantium	non recus tenetur a s reiciendis consequat asperiores Lorem ipsi adipiscing incididunt Ut enim ac exercitatio ea commo dolor in re cillum dolo
---	---

Figura 3: Saída final, com cada palavra circunscrita por um retângulo.

Os arquivos lorem_s12_c02_filtrada.pbm e lorem_s12_c02_palavras.pbm são gravados no mesmo diretório da imagem de entrada.

REFERÊNCIAS

- [1] GONZALEZ, R. C.; WOODS, R. E. **Processamento digital de imagens**. 3. ed. São Paulo: Pearson Prentice Hall, 2010.
- [2] PEDRINI, H.; SCHWARTZ, W. R. **Análise de imagens digitais: princípios, algoritmos e aplicações**. São Paulo: Thomson Learning, 2008.
- [3] POSKANZER, J. **PBM Format Specification**. Netpbm documentation. Disponível em: <https://netpbm.sourceforge.net/doc/pbm.html>. Acesso em: 4 jul. 2026.
- [4] WONG, K. Y.; CASEY, R. G.; WAHL, F. M. Document Analysis System. **IBM Journal of Research and Development**, v. 26, n. 6, p. 647-656, 1982. DOI: 10.1147/rd.266.0647.